

Classification Models for bank marketing

PROJECT 2

CONTENTS

1 Dataset

2 Logistic Regression

3 Decision Tree

4 Ensemble

5 Summary

Dataset Description

- **Bank Marketing Dataset**
  เป็นชุดข้อมูลเกี่ยวกับ**การทำการตลาดทางโทรศัพท์** โดยเก็บข้อมูล
  ลักษณะของลูกค้าและผลจากการติดต่อ ใน Marketing Campaign
  เพื่อทำนายว่าลูกค้าจะ**สมัคร Term Deposit หรือไม่**

- **4,521 instances**
- **16 input features**
- **1 target output: y (Term Deposit)**
- **Binary Classification**



Dataset

Data Exploration

```
Data types:
age            int64
job           object
marital       object
education     object
default       object
balance        int64
housing       object
loan          object
contact       object
day            int64
month         object
duration       int64
campaign       int64
pdays          int64
previous       int64
poutcome      object
y             object
```

```
Missing values:
age          0
job          0
marital      0
education    0
default      0
balance      0
housing      0
loan         0
contact      0
day          0
month        0
duration     0
campaign     0
pdays        0
previous     0
poutcome     0
y            0
dtype: int64
Number of duplicates: 0
```

10 Categorical Features
7 Numerical Features

ไม่พบ Missing Value
และ Duplicated data

Data Exploration

```
Target distribution:
y
no     4000
yes     521
Name: count, dtype: int64

Target proportion (%):
y
no     88.476001
yes    11.523999
Name: proportion, dtype: float64
```

พบว่าข้อมูลเป็น
imbalanced data

ใช้ F1-score ของ class yes
เป็น metric ในการวัด
performance ของ Model

Dataset

Dataset Preprocessing

	age	job	marital	education	default	balance	housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
0	30	unemployed	married	primary	no	1787	no	no	cellular	19	oct	79	1	-1	0	unknown	no
1	33	services	married	secondary	no	4789	yes	yes	cellular	11	may	220	1	339	4	failure	no
2	35	management	single	tertiary	no	1350	yes	no	cellular	16	apr	185	1	330	1	failure	no
3	30	management	married	tertiary	no	1476	yes	yes	unknown	3	jun	199	4	-1	0	unknown	no
4	59	blue-collar	married	secondary	no	0	yes	no	unknown	5	may	226	1	-1	0	unknown	no

จำนวนข้อมูล

(4521,17)

จำนวนข้อมูล

(4521,42)

- One-hot Encoding
- Feature Scaling
- Train-test Split 80 : 20

CONTENTS

1 Dataset

2 Logistic Regression

3 Decision Tree

4 Ensemble

5 Summary

What is Logistic Regression?

- เป็น **Model สำหรับ Classification**
- มีพื้นฐานจาก **Linear Regression**
- นำ Linear Output **ผ่าน Sigmoid Function**
  เพื่อแปลงเป็นค่า Probability (0–1)
- ใช้ **Threshold = 0.5** เพื่อเปลี่ยน Probability เป็น Class

Logistic Regression

Parameters

Parameter	หน้าที่	Default
C	**ควบคุมความแรง**ของ Regularization	1
solver	**Algorithm** ที่ใช้ในการ **Optimization**	lbfgs
class_weight	**กำหนดน้ำหนัก** ของแต่ละ Class	None

Objective

เพื่อศึกษา**ผลของการเปลี่ยนค่า C** ที่ควบคุมความแรงของ **Regularization** ต่อ Performance ของ Logistic Regression และ **หาค่า C ที่เหมาะสมกับชุดข้อมูลที่สุด**

Hypothesis

การเปลี่ยนค่า C จะทำให้ Performance ของ Logistic Regression แตกต่างกัน เนื่องจากค่า C ที่แตกต่างกันส่งผลต่อความแรงของ Regularization และความซับซ้อนของโมเดล

Experimental Plan : C

Experiment	C
Experiment1	0.01
Experiment2	0.1
Experiment3	1
Experiment4	10

C น้อย → Regularization แรง
C มาก → Regularization อ่อน

Logistic Regression

Results : C

Experiment	C	F1-SCORE
Experiment1	0.01	31.43%
Experiment2	0.1	40%
Experiment3	1	38.75%
Experiment4	10	38.50%

Best Ex Round 1

Objective

เพื่อ**ศึกษาผลของ Solver** ซึ่งเป็นวิธีการ **Optimization** ในการหาค่าพารามิเตอร์ของ Logistic Regression โดยใช้ Best C ร่วมกับ Solver แต่ละค่า เพื่อ**หา Solver ที่เหมาะสมที่สุดกับชุดข้อมูล**

Hypothesis

การเปลี่ยน Solver อาจทำให้ Performance แตกต่างกัน เนื่องจากแต่ละ Solver ใช้วิธีการ Optimization ที่แตกต่างกันในการหาค่า Weight

Experimental Plan : Solver

Experiment	C	Solver
Experiment5	0.1	lbfgs
Experiment6	0.1	liblinear
Experiment7	0.1	newton-cholesky

Results : Solver

Experiment	C	Solver	F1-SCORE
Experiment5	0.1	lbfgs	**40%**
Experiment6	0.1	liblinear	**38.71%**
Experiment7	0.1	newton-cholesky	**40%**



Objective

เพื่อ**ศึกษาผลของ Class Weight** ซึ่ง**กำหนดน้ำหนักให้แต่ละ Class** โดยใช้ Best C และ Best Solver จากการทดลองก่อนหน้า ร่วมกับ Class Weight แต่ละแบบ เพื่อ**หาวิธีที่เหมาะสมที่สุดกับชุดข้อมูล**

Hypothesis

การเปลี่ยน Class Weight อาจส่งผลต่อ Performance เนื่องจาก Dataset มี Class Imbalance และการกำหนดน้ำหนักช่วยให้โมเดลให้ความสำคัญกับแต่ละ Class แตกต่างกัน

Experimental Plan : Class weight

Experiment	C	Solver	Class_weight
Experiment5	0.1	lbfgs	None
Experiment8	0.1	lbfgs	balanced
Experiment7	0.1	newton-cholesky	None
Experiment9	0.1	newton-cholesky	balanced

Logistic Regression

Results : Class weight

Experiment	C	Solver	Class_weight	F1 - SCORE
Experiment5	0.1	lbfgs	None	40.00%
Experiment8	0.1	lbfgs	balanced	51.09%
Experiment7	0.1	newton-cholesky	None	40.00%
Experiment9	0.1	newton-cholesky	balanced	50.77%

Best Ex Round 3

Logistic Regression

Discuss Results



Logistic Regression

Discuss Results

LR	Experiment	PARAMETERS			F1-SCORE
		C	Solver	Class_weight	
1	1	0.01	-	-	**31.43%**
	2	0.1	-	-	**40%**
	3	1	-	-	**38.75%**
	4	10	-	-	**38.50%**
2	5	0.1	lbfgs	-	**40%**
	6	0.1	liblinear	-	**38.71%**
	7	0.1	newton-cholesky	-	**40%**
3	5	0.1	lbfgs	None	**40%**
	8	**0.1**	**lbfgs**	**balanced**	**51.09%**
	7	0.1	newton-cholesky	None	**40%**
	9	0.1	newton-cholesky	balanced	**50.77%**

Logistic Regression

Discuss Results

- จากการทดลองพบว่า **C = 0.1** ให้ F1-score สูงสุดใน รอบที่ 1 อยู่ที่ 40%
- เมื่อเปรียบเทียบ **Solver** พบว่า **lbfgs** และ **newton-cholesky** ให้ F1-score เท่ากันที่ 40%
- เมื่อเพิ่ม **class_weight="balanced"** พบว่า **F1-score เพิ่มขึ้นอย่างชัดเจน** โดย lbfgs + balanced ให้ค่าสูงสุดที่ 51.09%
- การที่ใช้ **balanced ให้ผลดีขึ้น** อาจเพราะ**ข้อมูลเป็น Imbalanced data** ทำให้โมเดลให้ความสำคัญกับ Class yes มากขึ้น

CONTENTS

1 Dataset

2 Logistic Regression

3 Decision Tree

4 Ensemble

5 Summary

What is Decision Tree?

- **โครงสร้าง** Root Node → Internal Node → Leaf Node
- ใช้แนวคิด **Greedy Strategy** “เลือก split ที่ดีที่สุด ณ ขณะนั้น”
- **Impurity** :ความปนกันของ class ใน node **ยิ่งปนมาก ค่า impurity สูง**
- **เป้าหมาย:** เลือก Split ที่ช่วย **ลด Impurity**
- **Stop splitting :** Node เป็น class เดียวหมด หรือถึงเงื่อนไขที่กำหนด

Decision Tree

Parameters

Parameter	หน้าที่	Default
Criterion	**วัด impurity** ของการแบ่งข้อมูล	GINI
max_depth	กำหนด**ความลึกสูงสุด**ของ Tree	None
CCP_alpha	ควบ**คุมระดับการตัดกิ่ง** ค่ายิ่งมาก ยิ่งตัดกิ่งมาก	0
min_samples_leaf	จำนวน**ตัวอย่างขั้นต่ำใน Leaf**	1
Class_weight	กำหนด**น้ำหนักของแต่ละ Class**	None

Objective

เพื่อ**ศึกษาผลของ Criterion** ซึ่งใช้วัดค่า impurity ของข้อมูล
เพื่อเลือกจุดแบ่งของ Tree และ**หา Criterion ที่เหมาะสมกับชุดข้อมูลนี้ที่สุด**

Hypothesis

การเปลี่ยน Criterion อาจทำให้ Performance แตกต่างกัน
เนื่องจากแต่ละ Criterion ใช้วิธีวัด Impurity ที่แตกต่างกันในการเลือกจุดแบ่งของ Tree

Experimental Plan : Criterion

Experiment	Criterion
Experiment1	Gini
Experiment2	Entropy

Decision Tree

Results : Criterion

Experiment	Criterion	F1-SCORE
Experiment1	Gini	**40%**
Experiment2	Entropy	**41.80%**



Best Ex Round 1

Objective

เพื่อ**ศึกษาการทำงานของ Pre-pruning และ Post-pruning** โดยใช้ Max Depth และ CCP Alpha ควบคุมการ Pruning ร่วมกับ Best Criterion **และหาวิธี pruning ที่เหมาะสมกับชุดข้อมูลนี้ที่สุด**

Hypothesis

การใช้ Pre-pruning และ Post-pruning อาจทำให้ Performance แตกต่างกัน เนื่องจากการควบคุมความซับซ้อนของ Tree ส่งผลต่อการแบ่งข้อมูลและการสร้าง Tree

Experimental Plan : Max_depth + CCP_alpha

Experiment	Criterion	Pruning	
		Max_depth	CCP_alpha
Experiment3	Entropy	5	0
Experiment4	Entropy	15	0
Experiment5	Entropy	20	0
Experiment6	Entropy	-	0.0014
Experiment7	Entropy	5	0.0014
Experiment8	Entropy	15	0.0014
Experiment9	Entropy	20	0.0014

Results : Max_depth + CCP_alpha

Experiment	Criterion	Pruning		F1-SCORE
		Max_depth	CCP_alpha	
Experiment3	Entropy	5	0	**36%**
Experiment4	Entropy	15	0	**47%**
Experiment5	Entropy	20	0	**44%**
Experiment6	Entropy	-	0.0014	**53.30%**
Experiment7	Entropy	5	0.0014	**44%**
Experiment8	Entropy	15	0.0014	**52.60%**
Experiment9	Entropy	20	0.0014	**53.10%**



Objective

เพื่อ**ศึกษาผลของ Min Samples Leaf** ซึ่งกำหนดจำนวนตัวอย่างขั้นต่ำใน Leaf ร่วมกับ Best Criterion และ Best CCP Alpha จากการทดลองก่อนหน้า และ**หาค่า Min Samples Leaf ที่เหมาะสมที่สุดกับชุดข้อมูลนี้ที่สุด**

Hypothesis

การเปลี่ยน Min Samples Leaf อาจส่งผลต่อ Performance เนื่องจากจำนวนตัวอย่างขั้นต่ำใน Leaf มีผลต่อความซับซ้อนของ Tree

Experimental Plan : min_samples_leaf

Experiment	Criterion	Pruning		min_samples_leaf
		Max_depth	CCP_alpha	
Experiment6	Entropy	-	0.0014	**-**
Experiment10	Entropy	-	0.0014	**3**
Experiment11	Entropy	-	0.0014	**5**
Experiment12	Entropy	-	0.0014	**7**

Results : min_samples_leaf

Experiment	Criterion	Pruning		min_samples_leaf	F1-SCORE
		Max_depth	CCP_alpha		
Experiment6	Entropy	-	0.0014	-	**53%**
Experiment10	Entropy	-	0.0014	3	**55%**
Experiment11	Entropy	-	0.0014	5	**54%**
Experiment12	Entropy	-	0.0014	7	**52%**



Objective

เพื่อ**ศึกษาผลของ Class Weight** ซึ่งกำหนดน้ำหนักให้แต่ละ Class ร่วมกับ Best Criterion, Best CCP Alpha และ Best Min Samples Leaf จากการทดลองก่อนหน้า และ**หาวิธีที่เหมาะสมกับชุดข้อมูลนี้ที่สุด**

Hypothesis

การเปลี่ยน Class Weight อาจส่งผลต่อ Performance เนื่องจาก Dataset มี Class Imbalance และการกำหนดน้ำหนักสามารถช่วยให้โมเดลให้ความสำคัญกับ Class ที่มีจำนวนน้อยมากขึ้น

Experimental Plan : Class weight

Experiment	Criterion	Pruning		min_samples_leaf	Class_weight
		Max_depth	CCP_alpha		
Experiment10	Entropy	-	0.0014	**3**	**-**
Experiment13	Entropy	-	0.0014	**3**	**balanced**

Decision Tree

Results : Class weight

Experiment	Criterion	Pruning		min_samples_leaf	class_weight	F1-SCORE
		Max_depth	CCP_alpha			
Experiment10	Entropy	-	0.0014	3	-	**55%**
Experiment13	Entropy	-	0.0014	3	balanced	**51%**

Best Ex Round 4

Decision Tree

Discuss Results



Decision tree

Discuss Results

DT	Experiment	PARAMETERS					F1-SCORE
		Criterion	Max_depth	CCP_alpha	min_samples_leaf	Class_weight	
1	1	Gini	-	-	-	-	40%
	2	Entropy	-	-	-	-	41.8%
2	3	Entropy	5	0	-	-	36%
	4	Entropy	15	0	-	-	47%
	5	Entropy	20	0	-	-	44%
	6	Entropy	-	0.0014	-	-	53.3%
	7	Entropy	5	0.0014	-	-	44%
	8	Entropy	15	0.0014	-	-	52.6%
	9	Entropy	20	0.0014	-	-	53.1%
3	6	Entropy	-	0.0014	-	-	53.3%
	10	**Entropy**	**-**	**0.0014**	**3**	**-**	**55%**
	11	Entropy	-	0.0014	5	-	54%
	12	Entropy	-	0.0014	7	-	52%
4	10	Entropy	-	0.0014	3	-	55%
	13	Entropy	-	0.0014	3	balanced	51%

Decision tree

Discuss Results

- **Entropy** ให้ F1-score **สูงกว่า Gini** ใน DT1 ที่ 41.80%
- การใช้ค่า **CCP Alpha** จากฟังก์ชัน **cost_complexity_pruning_path()** ให้ค่า F1-score ที่ 53.3%
- เมื่อเพิ่ม **Min Samples Leaf = 3** F1-score เพิ่มเป็น 55%
- แต่เมื่อเปลี่ยน **Class Weight** เป็น **balanced** F1-score **ลดลง**เหลือ 51%
- การที่ใช้ **balanced ให้ผลแย่ลง** อาจเพราะ balanced เปลี่ยนน้ำหนักของ Class ทำให้การเลือก Split ของ Tree เปลี่ยนไป และ**ไม่เหมาะกับการใช้ร่วมกับโมเดลนี้ในชุดข้อมูลนี้**

CONTENTS

1 Dataset

2 Logistic Regression

3 Decision Tree

4 Ensemble

5 Summary

What is Ensemble?

- **Ensemble Learning** คือการ**รวมผลการทำนายจากหลายโมเดล** เพื่อสร้างผลการทำนายร่วมกัน
- **3 แนวทางหลัก ๆ**
  - **Averaging** → Weighted averaging, Stacking, Voting
  - **Bagging** → Random Forest
  - **Boosting** → AdaBoost

Objective

เพื่อ**ศึกษาการทำงานของ Voting** โดยนำ Best Logistic Regression และ Best Decision Tree ที่มีลักษณะการเรียนรู้ที่แตกต่างกัน มารวมผลการทำนาย เปรียบเทียบ Performance และ**ดูว่าการรวมโมเดลเหมาะสมกับชุดข้อมูลนี้ไหม**

Hypothesis

การรวมผลการทำนายจาก Logistic Regression และ Decision Tree อาจช่วยให้ Performance ดีขึ้น เนื่องจากทั้งสองโมเดลมีกลไกในการตัดสินใจที่แตกต่างกัน

Experimental Plan : Best Experiment

Logistic Regression Model

Experiment	PARAMETERS			F1-SCORE
	C	Solver	Class_weight	
8	0.1	lbfgs	balanced	51.09%

Decision Tree Model

Experiment	PARAMETERS					F1-SCORE
	Criterion	Max_depth	CCP_alpha	min_samples_leaf	Class_weight	
10	Entropy	-	0.0014	3	-	55%

Experimental Plan : Hard Voting

Ensemble	Models	Voting	F1-SCORE
Voting	**Best** Logistic regression + **Best** Decision tree	Hard	**52.53%**

Ensemble

Discuss Results



Ensemble

Discuss Results

- **Hard Voting** ให้ F1-score 52.53%
  - **สูงกว่า** Logistic Regression
  - **ต่ำกว่า** Decision Tree
- อาจเพราะ **Hard Voting ให้น้ำหนัก Logistic Regression และ Decision Tree เท่ากัน** ทำให้**ผลทำนายของ Logistic Regression ส่งผลต่อการตัดสินใจของ Ensemble**

CONTENTS

1 Dataset

2 Logistic Regression

3 Decision Tree

4 Ensemble

5 Summary

SUMMARY

Model	Best Configuration	F1-SCORE
Logistic Regression	C=0.1 + lbfgs + balanced	**51.09%**
Decision Tree	Entropy + Best CCP + Leaf=3	**55%**
Ensemble	Hard Voting (Best LR + Best DT)	**52.53%**

SUMMARY

- Decision Tree ให้ F1-score สูงที่สุด
- อาจเพราะ **Decision Tree สามารถแบ่งข้อมูลตามเงื่อนไขของ Feature ได้เป็นลำดับ** ทำให้**จับความสัมพันธ์ของข้อมูลได้ดี**
- Hard Voting ให้ผลต่ำกว่า Decision Tree อาจเพราะผลของ Logistic Regression เข้ามามีผลต่อการตัดสินใจของ Ensemble
- จากการทดลองนี้ **Decision Tree ให้ Performance สูงที่สุด** และ**เหมาะสมที่สุดกับชุดข้อมูลนี้เมื่อพิจารณาจาก F1-score**

Code descriptions

Package	Function	หน้าที่
Pandas	read_csv()	อ่านข้อมูลจาก CSV
	get_dummies()	One-Hot Encoding ข้อมูล Categorical
NumPy	-	จัดการข้อมูลเชิงตัวเลข
Scikit-learn	train_test_split()	แบ่ง Training / Testing Data
	StandardScaler()	Scaling ข้อมูลสำหรับ Logistic Regression
	LogisticRegression()	สร้าง Logistic Regression Model
	DecisionTreeClassifier()	สร้าง Decision Tree Model
	VotingClassifier()	รวมผลการทำนายของหลายโมเดล
	accuracy_score()	คำนวณ Accuracy
	f1_score()	คำนวณ F1-score
	recall_score()	คำนวณ Recall
	precision_score()	คำนวณ Precision
	plot_tree()	แสดงโครงสร้าง Decision Tree

Members

1. นายนันทวัฒน์ ใจเที่ยง : 67102010399
2. นางสาวนาขวัญ จิตต์เอื้อเฟื้อ : 67102010400
3. นางสาวปุณณภา จึงเปี่ยมสุข : 67102010401

Q & A

